

Ejercicios del examen

Ejercicio 1. Sea X_1, \dots, X_n una muestra aleatoria de una densidad de probabilidad

$$f_X(x; \alpha) = \alpha x^{-2} \mathbf{1}_{[\alpha, \infty)}(x)$$

con $\alpha \in \Theta = (0, \infty)$.

- Encuentra un estimador máximo verosímil para α . $\alpha^* = X_{(1)}$
- ¿Es $X_{(1)} = \min\{X_1, \dots, X_n\}$ una estadística suficiente para α ?

Solución:

- Sea $\hat{\alpha}_{MV}$ el estimador de máxima verosimilitud para α . Sabemos que $\hat{\alpha}_{MV}$ es el parámetro que maximiza la función de verosimilitud, $L(\alpha)$. En otras palabras,

$$\hat{\alpha}_{MV} = \arg \max_{\alpha \in \Theta} L(\alpha)$$

Hay que encontrar en dónde (sobre su dominio) L alcanza su valor máximo. Primero calculamos la verosimilitud,


$$\begin{aligned} L(\alpha) &= f_{X_1, \dots, X_n}(x_1, \dots, x_n; \alpha) \\ &= \prod_{i=1}^n f_{X_i}(x_i; \alpha) \\ &= \prod_{i=1}^n \alpha x_i^{-2} \mathbf{1}_{[\alpha, \infty)}(x_i) \\ &= \alpha^n \left(\prod_{i=1}^n x_i \right)^{-2} \prod_{i=1}^n \mathbf{1}_{[\alpha, \infty)}(x_i) \end{aligned}$$

Si existe $j \in \{1, \dots, n\}$ tal que $x_j < \alpha$, entonces $\mathbf{1}_{[\alpha, \infty)}(x_j) = 0$, y $L(\alpha) = 0$ para toda α . Entonces,

$$x_j < \alpha \Rightarrow \mathbf{1}_{[\alpha, \infty)}(x_j) = 0 \Rightarrow L(\alpha, x) = 0$$

$$\begin{aligned} L(\alpha) &= \alpha^n \left(\prod_{i=1}^n x_i \right)^{-2} \prod_{i=1}^n \mathbf{1}_{[\alpha, \infty)}(x_i) \\ &= \alpha^n \left(\prod_{i=1}^n x_i \right)^{-2} \mathbf{1}_{[\alpha, \infty)}(x_{(1)}) \end{aligned}$$

Si sup. que no existe esa x_j



Nótese que como $\alpha > 0$, entonces L es una función estrictamente creciente, por lo que esperamos que el máximo lo alcance hacia la derecha. Sea $\alpha^* = X_{(1)} = \min\{X_1, \dots, X_n\}$.

Si $\alpha^{**} > \alpha^*$, entonces $\mathbf{1}_{[\alpha^{**}, \infty)}(x_{(1)}) = 0$ y $L(\alpha^*) > L(\alpha^{**})$.

Si $\alpha^{**} < \alpha^*$, por ser L creciente, $L(\alpha^{**}) < L(\alpha^*)$.

Es decir,

$$\alpha^* = \arg \max_{\alpha \in \Theta} L(\alpha)$$

Entonces $\hat{\alpha}_{MV} = X_{(1)}$

- Del inciso anterior,

$$\begin{aligned} L(\alpha) &= \alpha^n \mathbf{1}_{[\alpha, \infty)}(x_{(1)}) \left(\prod_{i=1}^n x_i \right)^{-2} \\ &= g(S(\underline{x}), \alpha) h(\underline{x}) \end{aligned}$$

con $g(S(\underline{x}), \alpha) = \alpha^n \mathbf{1}_{[\alpha, \infty)}(x_{(1)})$ y $h(\underline{x}) = \prod_{i=1}^n x_i^{-2}$. Por el teorema de factorización, $S(\underline{X}) = X_{(1)}$ es una estadística suficiente.

$$x < y \Rightarrow f(x) < f(y)$$

$$\alpha^{***} < \alpha^* \Rightarrow L(\alpha^{***}) < L(\alpha^*)$$

Ejercicio 2. Sea X_1, \dots, X_5 una muestra aleatoria de una distribución $\mathcal{N}(\mu, \sigma^2)$. Sean

$$T_1(\underline{X}) = \frac{1}{5} \sum_{i=1}^5 X_i$$

$$T_2(\underline{X}) = \frac{1}{4} \sum_{i=1}^5 X_i$$

dos estimadores para μ . ¿Qué estimador tiene menor error cuadrático medio?

Solución:

Sabemos que,

$$ECM_T(\mu) = \text{Var}(T) + \beta(\mu)^2$$

con $\beta(\mu) = \mathbb{E}(T) - \mu$.

Como $X_i \sim \mathcal{N}(\mu, \sigma^2)$, entonces

$$T_1(\underline{X}) \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{5}\right)$$

$$\frac{4}{5}T_2(\underline{X}) \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{5}\right)$$

Entonces,

$$\begin{aligned} ECM_{T_1}(\mu) &= \text{Var}(T_1) + \beta(\mu)^2 \\ &= \frac{\sigma^2}{5} + (\mu - \mu)^2 \\ &= \frac{\sigma^2}{5} \end{aligned}$$

Por otro lado,

$$\begin{aligned} ECM_{T_2}(\mu) &= \text{Var}(T_2) + \beta(\mu)^2 \\ &= \text{Var}\left(\frac{5}{4} \frac{4}{5} T_2\right) + \left(\frac{5}{4} \mathbb{E}\left(\frac{4}{5} T_2\right) - \mu\right)^2 \\ &= \frac{25}{16} \frac{\sigma^2}{5} + \frac{1}{16} \mu^2 \\ &= \frac{5}{16} \sigma^2 + \frac{1}{16} \mu^2 \end{aligned}$$

Como $\frac{1}{16} \mu^2 > 0$ y $\frac{5}{16} \sigma^2 > \frac{1}{5} \sigma^2$, entonces

$$\begin{aligned} \frac{5}{16} \sigma^2 + \frac{1}{16} \mu^2 &> \frac{1}{5} \sigma^2 \\ ECM_{T_2}(\mu) &> ECM_{T_1}(\mu) \end{aligned}$$

Por lo tanto, T_1 tiene menor error cuadrático medio (i.e es un mejor estimador que T_2).

Ejercicio 3. Sea X_1, \dots, X_n una m. a. de una distribución $Poisson(\lambda)$.

$$f(x; \lambda) = \frac{e^{-\lambda} \lambda^x}{x!} \mathbb{1}_{\mathbb{N}}(x)$$

Considere a $\hat{\lambda} = \bar{X}$ como un estimador para λ .

1. Encuentre la CICR para $Var(\bar{\lambda})$.
2. El estimador $\hat{\lambda}$, ¿es consistente?

Solución.

1. Obsérvese que,

$$\begin{aligned} \mathbb{E}(\hat{\lambda}) &= \mathbb{E}(\bar{X}) \\ &= \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) \\ &= \frac{1}{n} \sum_{i=1}^n \lambda \\ &= \frac{1}{n} (n\lambda) \\ &= \lambda \end{aligned}$$

De aquí, se sigue que el estimador $\hat{\lambda}$ es insesgado.

Además, $\tau(\lambda) = \lambda$, por lo que $(\tau'(\lambda))^2 = 1$.

A continuación, se obtendrá la información esperada de Fisher.

Nótese que,

$$\begin{aligned} \frac{\partial}{\partial \lambda} \ln(f(x; \lambda)) &= \frac{\partial}{\partial \lambda} \ln\left(\frac{e^{-\lambda} \lambda^x}{x!} \mathbb{1}_{\mathbb{N}}(x)\right) \\ &= \frac{\partial}{\partial \lambda} (-\lambda + x \ln(\lambda) + \ln\left(\frac{1}{x!} \mathbb{1}_{\mathbb{N}}(x)\right)) \\ &= -1 + \frac{x}{\lambda} \\ &= \frac{x - \lambda}{\lambda}. \end{aligned}$$

Luego,

$$\begin{aligned} I_{\underline{X}}(\lambda) &= n \mathbb{E}\left(\left(\frac{\partial}{\partial \lambda} \ln(f(X; \lambda))\right)^2\right) \\ &= n \mathbb{E}\left(\left(\frac{X - \lambda}{\lambda}\right)^2\right) \\ &= n \mathbb{E}\left(\frac{(X - \lambda)^2}{\lambda^2}\right) \\ &= \frac{n}{\lambda^2} \mathbb{E}((X - \lambda)^2) \\ &= \frac{n}{\lambda^2} \mathbb{E}((X - \mathbb{E}(X))^2) \\ &= \frac{n}{\lambda^2} \text{Var}(X) \\ &= \frac{n}{\lambda^2} \lambda \\ &= \frac{n}{\lambda}. \end{aligned}$$

Con lo obtenido hasta ahora, se sigue que,

$$\begin{aligned} CICR(\lambda) &= \frac{(\tau'(\lambda))^2}{I_{\underline{X}}(\lambda)} \\ &= \frac{1}{\frac{n}{\lambda}} \\ &= \frac{\lambda}{n}. \end{aligned}$$

Al ser λ insesgado, se sigue que $\mathbb{V}ar(\widehat{\lambda}) \geq CICR(\lambda) = \frac{\lambda}{n}$.

2. Para cada $n \in \mathbb{N}$, sea $\widehat{\lambda}_n := \frac{1}{n} \sum_{i=1}^n X_i$.
Sea $n \in \mathbb{N}$.
Se tiene que,

$$\begin{aligned} \mathbb{V}ar(\widehat{\lambda}_n) &= \mathbb{V}ar\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}ar(X_i) \\ &= \frac{1}{n^2} (n\lambda) \\ &= \frac{\lambda}{n}. \end{aligned}$$

Cada $\widehat{\lambda}_n$ es insesgado, así que, $ECM(\widehat{\lambda}_n) = \mathbb{V}ar(\widehat{\lambda}_n) = \frac{\lambda}{n}$.
Luego,

$$\begin{aligned} \lim_{n \rightarrow \infty} ECM(\widehat{\lambda}_n) &= \lim_{n \rightarrow \infty} \mathbb{V}ar(\widehat{\lambda}_n) \\ &= \lim_{n \rightarrow \infty} \frac{\lambda}{n} \\ &= 0. \end{aligned}$$

Así, se tiene que, en efecto, $\widehat{\lambda}$ es un estimador consistente para λ .

Ejercicio 4. Sea Y_1, \dots, Y_n una m.a. de una distribución con función de densidad de probabilidad

$$f_Y(y; \theta) = \theta(1 - \theta)^y \mathbb{1}_{\mathbb{N}}(y),$$

donde $\theta \in (0, 1)$, $\mathbb{E}(Y) = \frac{\theta}{1-\theta}$, y $\text{Var}(Y) = \frac{\theta}{(1-\theta)^2}$.

1. Encuentre el estimador por momentos para $\tau(\theta) = \frac{\theta}{1-\theta}$.
2. ¿Su estimador es un UMVUE?

Solución.

1. Dado que la función de densidad de probabilidad de la muestra sólo depende de un parámetro, se sigue que el sistema de ecuaciones a resolver, es,

$$\mu_1 = M_1,$$

donde μ_1 es el primer momento poblacional, es decir $\mathbb{E}(Y_i)$, y M_1 es el primer momento muestral, es decir, $\frac{1}{n} \sum_{i=1}^n Y_i$.

Por un lado, está dado que, $\mathbb{E}(Y) = \frac{\theta}{1-\theta} = \tau(\theta)$.

Así, $\mu_1 = \tau(\theta)$.

Luego, el sistema resulta,

$$\tau(\theta) = \frac{1}{n} \sum_{i=1}^n Y_i,$$

a resolver para $\tau(\theta)$.

Se sigue, entonces, que el estimador por momentos para $\tau(\theta)$, es $\widehat{\tau(\theta)} = \frac{1}{n} \sum_{i=1}^n Y_i$.

2. Obsérvese lo siguiente:

$$\begin{aligned} f(y; \theta) &= \theta(1 - \theta)^y \mathbb{1}_{\mathbb{N}}(y) \\ &= \theta \mathbb{1}_{\mathbb{N}}(y) e^{y \ln(1-\theta)} \end{aligned}$$

Haciendo $a(\theta) := \theta$, $b(y) := \mathbb{1}_{\mathbb{N}}(y)$, $c(\theta) := \ln(1 - \theta)$, $d(y) := y$, se deduce que la función de densidad de la muestra pertenece a la familia exponencial.

Sea $S : \mathbb{R}^n \rightarrow \mathbb{R}$, $S(x_1, \dots, x_n) := \sum_{i=1}^n x_i$.

Dado que la $d(y) = y$, se sigue que, el estimador $\sum_{i=1}^n d(Y_i) = \sum_{i=1}^n Y_i = S(\underline{Y})$, es suficiente y completo.

Sea $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) := \frac{1}{n}x$.

Sea $T^* := f \circ S$. Esto refleja que T^* es función de S .

Adviértase que $T^*(\underline{Y}) = \widehat{\tau(\theta)}$.

Además,

$$\begin{aligned} \mathbb{E}(T^*(\underline{Y})) &= \mathbb{E}(\bar{Y}) \\ &= \frac{\theta}{1-\theta} \\ &= \tau(\theta) \end{aligned}$$

Por ende, $T^*(\underline{Y})$ es un estimador insesgado para $\tau(\theta)$.

Del Teorema de Lehmann-Scheffé, se puede concluir que $T^*(\underline{Y}) = \widehat{\tau(\theta)}$ es el UMVUE de $\tau(\theta)$.