



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS

Tarea 2

Integrantes:

Yonathan Berith Jaramillo Ramírez. 419004640

Dalia Viridiana Martínez Retiz. 309213293

Alejandro Sánchez Campos. 310131786

Profesor: Ruth Selene Fuentes García

Ayudante: Carlos Alberto Arriaga Solórzano



15 Octubre, 2023

Se pueden encontrar las respuestas resueltas en el repo:
<https://github.com/Yony6041/statistics>

1. Sea X_1, \dots, X_n una m.a. con

$$f_X(x; \theta) = \theta x^{\theta-1} I_{(0,1)}^{(x)}$$

donde $\theta > 0$. Encuentre el estimador de momentos y el estimador máximo verosímil para θ .

Respuesta:

Conceptos

(a) **Función de Densidad de Probabilidad (PDF)**

La función de densidad de probabilidad $f_X(x; \theta) = \theta x^{\theta-1} I_{(0,1)}^{(x)}$ está definida para x en el intervalo $(0, 1)$ y $\theta > 0$. Aquí, $I_{(0,1)}^{(x)}$ es la función indicadora, que es igual a 1 si x está en el intervalo $(0, 1)$ y 0 en caso contrario. Esta función describe cómo se distribuyen los datos en función de θ .

(b) **Método de los Momentos**

El método de los momentos es una técnica de estimación de parámetros. La idea básica es igualar los momentos muestrales a los momentos teóricos de la distribución y resolver para el parámetro desconocido. En términos matemáticos, el k -ésimo momento alrededor del origen está dado por:

$$E[X^k] = \int_{-\infty}^{\infty} x^k f_X(x; \theta) dx$$

Este es un concepto fundamental en estadística para entender cómo se distribuyen los datos.

Resolución del ejercicio 1

Calcular el Primer Momento Teórico

Para calcular el primer momento teórico $E[X]$, necesitamos evaluar la siguiente integral:

$$E[X] = \int_0^1 x \theta x^{\theta-1} dx$$

Primero, simplificamos la expresión dentro de la integral:

$$\theta x^{\theta-1} \times x = \theta x^{\theta}$$

Ahora, la integral se convierte en:

$$E[X] = \theta \int_0^1 x^{\theta} dx$$

Para resolver esta integral, utilizamos la fórmula de la integral de potencias de x , que es:

$$\int x^n dx = \frac{x^{n+1}}{n+1} + C$$

Aplicando esta fórmula, obtenemos:

$$\theta \left[\frac{x^{\theta+1}}{\theta+1} \right]_0^1$$

Evaluamos la integral definida en los límites 0 y 1:

$$= \theta \left(\frac{1^{\theta+1}}{\theta+1} - \frac{0^{\theta+1}}{\theta+1} \right)$$

$$= \theta \left(\frac{1}{\theta+1} - 0 \right)$$

$$= \frac{\theta}{\theta+1}$$

$$\bar{X} = \frac{\theta}{\theta+1}$$

Igualar el Momento Teórico al Momento Muestral

El primer momento muestral es simplemente la media aritmética de la muestra. Si tienes una muestra X_1, X_2, \dots, X_n , la media muestral \bar{X} se calcula como:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Este es un estadístico que se calcula directamente a partir de los datos de la muestra y sirve como una estimación del primer momento teórico $E[X]$.

Ahora, igualamos este primer momento muestral al primer momento teórico que calculamos previamente:

$$\bar{X} = \frac{\theta}{\theta + 1}$$

Resolvemos para θ :

$$\bar{X}(\theta + 1) = \theta$$

$$\bar{X}\theta + \bar{X} = \theta$$

$$\bar{X}\theta = \theta - \bar{X}$$

$$\theta(\bar{X} - 1) = -\bar{X}$$

$$\theta = -\frac{\bar{X}}{\bar{X} - 1}$$

Conclusión

El estimador de momentos para θ es $-\frac{\bar{X}}{\bar{X}-1} \therefore$

Estimador máximo verosímil para θ

Dada una muestra aleatoria X_1, \dots, X_n con función de densidad de probabilidad

$$f_X(x; \theta) = \theta x^{\theta-1} I_{(0,1)}^{(x)},$$

donde $\theta > 0$, se busca encontrar el estimador de máxima verosimilitud (EMV) para θ .

Solución

(a) **Función de Verosimilitud**

La función de verosimilitud $L(\theta)$ está dada por el producto de las funciones de densidad individuales para cada observación X_i :

Separando términos, aplicando la propiedad distributiva y simplificando los terminos obtenemos:

$$L(\theta) = \prod_{i=1}^n f_X(x_i; \theta) = \prod_{i=1}^n (\theta x_i^{\theta-1}) = \theta^n \prod_{i=1}^n x_i^{\theta-1}.$$

(b) **Log-Verosimilitud**

Es más fácil trabajar con la log-verosimilitud, $\ell(\theta)$, que es el logaritmo natural de $L(\theta)$:

$$\ell(\theta) = \ln(L(\theta)) = \ln \left(\theta^n \prod_{i=1}^n x_i^{\theta-1} \right) = n \ln(\theta) + (\theta - 1) \sum_{i=1}^n \ln(x_i).$$

(c) **Derivadas**

Para encontrar el EMV, derivamos la log-verosimilitud con respecto a θ y resolvemos para θ cuando la derivada es igual a cero:

$$\frac{d\ell}{d\theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln(x_i) = 0.$$

1. Multiplicamos todos los términos por θ para eliminar el denominador en el primer término:

$$n + \theta \sum_{i=1}^n \ln(x_i) = 0$$

2. Ahora, queremos aislar θ , así que movemos el término n al otro lado de la ecuación:

$$\theta \sum_{i=1}^n \ln(x_i) = -n$$

3. Finalmente, dividimos ambos lados de la ecuación por $\sum_{i=1}^n \ln(x_i)$ (asumiendo que la suma de los logaritmos no es cero) para despejar θ :

$$\theta = -\frac{n}{\sum_{i=1}^n \ln(x_i)}$$

(d) **Segunda Derivada**

Para confirmar que es un máximo, la segunda derivada de la log-verosimilitud debe ser negativa:

$$\frac{d^2\ell}{d\theta^2} = -\frac{n}{\theta^2} < 0.$$

Dado que $\theta > 0$ y $n > 0$, la segunda derivada es siempre negativa, lo que confirma que el valor encontrado es un máximo.

(e) **Estimador de Máxima Verosimilitud**

Por lo tanto, el estimador de máxima verosimilitud (EMV) para θ es:

$$\hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln(x_i)}.$$

2. Consideren el siguiente ejemplo: para un experimento se toma una muestra aleatoria de tamaño 15, observando los siguientes resultados: (3,5,2,1,1,1,1,8,0,2,2,0,3,5,2). Asumiendo que la muestra aleatoria X_1, \dots, X_{15} viene de una población Poisson(λ).

Respuesta:

Estimador Máximo Verosímil para λ

Para encontrar el estimador de máxima verosimilitud (MLE) para λ , primero definimos la función de verosimilitud para una distribución de Poisson:

$$L(\lambda|X_1, \dots, X_{15}) = \prod_{i=1}^{15} \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}$$

Donde x_i son los datos observados.

En este caso, $x = (3, 5, 2, 1, 1, 1, 1, 8, 0, 2, 2, 0, 3, 5, 2)$.

Utilizando las leyes de logaritmos:

- $\log(a^b) = b \log(a)$ (Ley de exponentes)
- $\log\left(\frac{a}{b}\right) = \log(a) - \log(b)$ (Propiedad de división)
- $\log(a \times b) = \log(a) + \log(b)$ (Propiedad de multiplicación)
- $\log(e^x) = x$ (Ley de Euler para logaritmos)

La función de log-verosimilitud es:

$$\begin{aligned}\log L(\lambda|X_1, \dots, X_{15}) &= \sum_{i=1}^{15} \left(\log \left(\frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \right) \right) \\ &= \sum_{i=1}^{15} (\log(\lambda^{x_i}) + \log(e^{-\lambda}) - \log(x_i!)) \\ &= \sum_{i=1}^{15} (x_i \log(\lambda) - \lambda - \log(x_i!))\end{aligned}$$

Derivando con respecto a λ e igualando a cero:

Reglas para las derivadas:

- $\frac{d}{dx} \log(x) = \frac{1}{x}$ (Derivada del logaritmo natural)
- $\frac{d}{dx} x = 1$ (Derivada de una variable respecto a sí misma)
- $\frac{d}{dx} c = 0$ (Derivada de una constante)
- $\frac{d}{dx} [u(x) \cdot v(x)] = u'(x) \cdot v(x) + u(x) \cdot v'(x)$ (Regla del producto)

Primero, partimos de la función de log-verosimilitud, que es:

$$\log L(\lambda|X_1, \dots, X_{15}) = \sum_{i=1}^{15} (x_i \log(\lambda) - \lambda - \log(x_i!))$$

Para maximizar esta función con respecto a λ , derivamos $\log L(\lambda|X_1, \dots, X_{15})$ respecto a λ e igualamos a cero. Utilizando la regla de la suma para derivadas, tenemos:

$$\frac{d}{d\lambda} \left(\sum_{i=1}^{15} (x_i \log(\lambda) - \lambda - \log(x_i!)) \right) = \sum_{i=1}^{15} \frac{d}{d\lambda} (x_i \log(\lambda) - \lambda - \log(x_i!))$$

Para derivar $x_i \log(\lambda)$, utilizamos la regla del producto:

$$\frac{d}{d\lambda} (x_i \log(\lambda)) = x_i \frac{1}{\lambda} + 0 = \frac{x_i}{\lambda}$$

El término $-\lambda$ tiene una derivada de -1 , y el término $\log(x_i!)$ es una constante respecto a λ , por lo que su derivada es cero.

Al sumar todos estos términos, obtenemos:

$$\sum_{i=1}^{15} \left(\frac{x_i}{\lambda} - 1 \right)$$

Simplificamos y agrupamos los términos:

$$\begin{aligned} &= \left(\sum_{i=1}^{15} \frac{x_i}{\lambda} \right) + \left(\sum_{i=1}^{15} -1 \right) \\ &= \left(\sum_{i=1}^{15} \frac{x_i}{\lambda} \right) - 15 \\ &= \frac{1}{\lambda} \left(\sum_{i=1}^{15} x_i \right) - 15 \\ &\frac{1}{\lambda} \left(\sum_{i=1}^{15} x_i \right) - 15 = 0 \end{aligned}$$

Despejando λ_{MLE} , llegamos a:

Para despejar λ , el primer paso es llevar el término -15 al otro lado de la ecuación:

$$\frac{1}{\lambda} \left(\sum_{i=1}^{15} x_i \right) = 15$$

El siguiente paso es multiplicar ambos lados de la ecuación por λ :

$$\lambda \times \frac{1}{\lambda} \left(\sum_{i=1}^{15} x_i \right) = 15 \times \lambda$$

Simplificamos, y obtenemos:

$$\sum_{i=1}^{15} x_i = 15\lambda$$

Finalmente, dividimos ambos lados entre 15 para despejar λ :

$$\lambda_{MLE} = \frac{\sum_{i=1}^{15} x_i}{15}$$

Este valor de λ_{MLE} es el estimador de máxima verosimilitud para λ .

Estimador Máximo Verosímil para $\tau(\lambda) = P(X = 1)$

Contexto de la Distribución de Poisson

Una distribución de Poisson es utilizada para modelar el número de eventos que ocurren en un intervalo fijo de tiempo o espacio, bajo la suposición de que estos eventos ocurren con una tasa constante y de forma independiente. La función de probabilidad (PMF) para una variable aleatoria X que sigue una distribución de Poisson con parámetro λ está dada por:

$$P(X = k) = \frac{\lambda^k \cdot e^{-\lambda}}{k!}$$

Aquí, λ es la tasa promedio de ocurrencia de eventos, k es el número específico de eventos, y e es la base del logaritmo natural (2.71828).

Evaluación para $X = 1$

Cuando estamos interesados en la probabilidad de que exactamente un evento ocurra ($X = 1$), sustituimos $k = 1$ en la PMF de Poisson:

$$P(X = 1) = \frac{\lambda^1 \cdot e^{-\lambda}}{1!}$$

Observe que $\lambda^1 = \lambda$ y $1! = 1$, simplificando la expresión a:

$$P(X = 1) = \lambda e^{-\lambda}$$

Interpretación

La expresión $\lambda e^{-\lambda}$ nos da la probabilidad de que exactamente un evento ocurra en el intervalo observado, dado que la tasa promedio de eventos es λ . λ actúa como una especie de "peso" para un solo evento, mientras que $e^{-\lambda}$ es un factor que decae exponencialmente con el aumento de λ , limitando la probabilidad a un valor entre 0 y 1.

Para $\tau(\lambda) = P(X = 1)$, sabemos que para una distribución de Poisson:

$$P(X = 1) = \lambda e^{-\lambda}$$

Sustituimos λ_{MLE} en esta ecuación para encontrar $\tau(\lambda_{MLE})$:

(a) **¿Qué es λ_{MLE} ?**

La notación λ_{MLE} se refiere al Estimador de Máxima Verosimilitud (MLE, por sus siglas en inglés) del parámetro λ de una distribución de Poisson. En este contexto, λ representa la tasa promedio de ocurrencias de un evento en un intervalo de tiempo o espacio determinado.

(b) **Cálculo de λ_{MLE}**

El cálculo del λ_{MLE} en una distribución de Poisson se da mediante la fórmula:

$$\lambda_{MLE} = \frac{\sum_{i=1}^{15} x_i}{15}$$

Donde $\sum_{i=1}^{15} x_i$ es la suma de 15 observaciones de datos. Asumimos que la suma de estas observaciones es 36, es decir, $\sum_{i=1}^{15} x_i = 36$.

(c) **Sustitución en la fórmula del λ_{MLE}**

Al reemplazar la suma en la fórmula, obtenemos:

$$\lambda_{MLE} = \frac{36}{15}$$

Este es el valor que se utilizará en la ecuación $\tau(\lambda_{MLE})$.

(d) **Cálculo de $\tau(\lambda_{MLE})$**

Finalmente, $\tau(\lambda)$ en una distribución de Poisson se define como $P(X = 1)$, que es igual a $\lambda e^{-\lambda}$. Sustituimos λ_{MLE} en esta ecuación para encontrar $\tau(\lambda_{MLE})$:

$$\tau(\lambda_{MLE}) = \frac{36}{15} \times e^{-\frac{36}{15}} \approx 0.22$$

Estimador puntual para λ

Si asumimos que nuestro conocimiento o experiencia previa sobre λ puede expresarse a través de una distribución $\pi(\lambda) = \text{gamma}(4, 2)$ encuentra la distribución posterior para λ de acuerdo al enfoque Bayesiano de estimación. ¿Cuál sería un estimador puntual para λ ?

Nota: recuerda que la distribución final

$$\pi(\lambda|X_1, \dots, X_{15}) = \frac{L(\lambda|X_1, \dots, X_{15})\pi(\lambda)}{\int_0^\infty L(\lambda|X_1, \dots, X_{15})\pi(\lambda)d\lambda}$$

Estimación Bayesiana de λ

Introducción

Para resolver este problema, necesitamos definir algunos conceptos clave en el enfoque Bayesiano:

- Distribución a priori ($\pi(\lambda)$): Es la distribución que representa nuestro conocimiento previo sobre el parámetro λ . En este caso, se nos da que $\pi(\lambda) = \text{gamma}(4, 2)$.
- Distribución de la muestra ($p(x|\lambda)$): Esta es la distribución de los datos observados dado un valor del parámetro λ . Asumiremos que no se proporciona esta información, pero en un problema típico relacionado con tasas o conteos, uno podría considerar una distribución Poisson para la muestra.
- Distribución posterior ($\pi(\lambda|x)$): Es la distribución de λ después de observar los datos. Según la teoría Bayesiana, se calcula como:

$$\pi(\lambda|x) \propto p(x|\lambda)\pi(\lambda)$$

Desarrollo

Empezaremos asumiendo una distribución de la muestra. Dado que estamos hablando de λ , es común que se utilice la distribución de Poisson para modelar el número de eventos que ocurren en un intervalo fijo de tiempo o espacio. En una distribución de Poisson, la función de probabilidad está dada por:

$$p(x|\lambda) = \frac{\lambda^x e^{-\lambda}}{x!}$$

La distribución gamma a priori está dada por:

$$\pi(\lambda) = \frac{\beta^\alpha \lambda^{\alpha-1} e^{-\beta\lambda}}{\Gamma(\alpha)} = \text{gamma}(\alpha, \beta)$$

Donde $\alpha = 4$ y $\beta = 2$.

Ahora, aplicamos el teorema de Bayes para encontrar la distribución posterior $\pi(\lambda|x)$:

$$\pi(\lambda|x) \propto p(x|\lambda)\pi(\lambda)$$

$$\pi(\lambda|x) \propto \left(\frac{\lambda^x e^{-\lambda}}{x!} \right) \left(\frac{\beta^\alpha \lambda^{\alpha-1} e^{-\beta\lambda}}{\Gamma(\alpha)} \right)$$

$$\pi(\lambda|x) \propto \lambda^{x+\alpha-1} e^{-(\lambda+\beta)}$$

Este es otro ejemplo de una distribución gamma, específicamente $\text{gamma}(x + \alpha, \lambda + \beta)$.

Estimador Puntual

Para encontrar un estimador puntual de λ , podemos utilizar el valor esperado de la distribución posterior, que para una distribución gamma $\text{gamma}(\alpha, \beta)$ es $\frac{\alpha}{\beta}$.

En este caso, el estimador puntual sería $\frac{x+\alpha}{\lambda+\beta}$.

3. Considere dos estimadores, basados en una m.a. de n observaciones, $t_1(X)$ y $t_2(X)$ del parámetro σ^2 en la distribución normal con media μ conocida.

$$f(x) = \frac{1}{(\sigma^2 2\pi)^{1/2}} \exp \left(-\frac{(x - \mu)^2}{2\sigma^2} \right),$$

$$t_1(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2,$$

$$t_2(X) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Demuestre que $t_1(X)$ y $t_2(X)$ son estimadores insesgados del parámetro σ^2 .

Demostración de Estimadores Insesgados

Para demostrar que $t_1(X)$ y $t_2(X)$ son estimadores insesgados de σ^2 , necesitamos mostrar que $E[t_i(X)] = \sigma^2$ para $i = 1, 2$.

Demostración para $t_1(X)$

Primero, calculemos la esperanza de $t_1(X)$:

$$\begin{aligned}
E[t_1(X)] &= E \left[\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \right] \\
&= \frac{1}{n} \sum_{i=1}^n E[(x_i - \mu)^2] \\
&= \frac{1}{n} \sum_{i=1}^n \sigma^2 \\
&= \frac{1}{n} \cdot n \cdot \sigma^2 \\
&= \sigma^2.
\end{aligned}$$

Demostración para $t_2(X)$

Ahora, calculemos la esperanza de $t_2(X)$:

$$\begin{aligned}
E[t_2(X)] &= E \left[\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \right] \\
&= \frac{1}{n-1} E \left[\sum_{i=1}^n x_i^2 - 2x_i\bar{x} + \bar{x}^2 \right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n E[x_i^2] - 2E[x_i\bar{x}] + E[\bar{x}^2] \right].
\end{aligned}$$

También sabemos que $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

Dado que x_i es normalmente distribuido con varianza σ^2 , $E[x_i^2] = \sigma^2 + \mu^2$.

Se puede demostrar que $E[\bar{x}^2] = \frac{\sigma^2}{n} + \mu^2$ y $E[x_i\bar{x}] = \mu^2 + \frac{\sigma^2}{n}$.

Substituyendo estos en nuestra fórmula, llegamos a:

$$E[t_2(X)] = \sigma^2.$$

Por lo tanto, ambos $t_1(X)$ y $t_2(X)$ son estimadores insesgados de σ^2 .

- Suponga que $E[\hat{\theta}_1] = E[\hat{\theta}_2]$ y que $Var[\hat{\theta}_1] = \sigma_1$, $Var[\hat{\theta}_2] = \sigma_2$, con $\hat{\theta}_1$ independiente de $\hat{\theta}_2$. Se define el siguiente estimador:

$$\hat{\theta}_3 = a\hat{\theta}_1 + (1-a)\hat{\theta}_2.$$

- (a) ¿Es $\hat{\theta}_3$ un estimador insesgado para θ ?
- (b) ¿Para qué valor de la constante a se minimiza la varianza de $\hat{\theta}_3$?
- (c) ¿Para qué valor de la constante a se minimiza la varianza de $\hat{\theta}_3$ si ahora $\hat{\theta}_1$ y $\hat{\theta}_2$ no son independientes pero son tales que $Cov(\hat{\theta}_1, \hat{\theta}_2) = c \neq 0$?

Estimador Compuesto $\hat{\theta}_3$

- (a) **¿Es $\hat{\theta}_3$ un estimador insesgado para θ ?**

Para determinar si $\hat{\theta}_3$ es un estimador insesgado, necesitamos calcular su valor esperado $E[\hat{\theta}_3]$ y verificar si es igual a θ :

$$\begin{aligned} E[\hat{\theta}_3] &= E[a\hat{\theta}_1 + (1-a)\hat{\theta}_2] \\ &= aE[\hat{\theta}_1] + (1-a)E[\hat{\theta}_2] \\ &= a\theta + (1-a)\theta \\ &= \theta. \end{aligned}$$

Dado que $E[\hat{\theta}_3] = \theta$, $\hat{\theta}_3$ es un estimador insesgado para θ .

- (b) **¿Para qué valor de la constante a se minimiza la varianza de $\hat{\theta}_3$?**

Para minimizar la varianza de $\hat{\theta}_3$, primero necesitamos encontrar $Var[\hat{\theta}_3]$:

$$\begin{aligned} Var[\hat{\theta}_3] &= Var[a\hat{\theta}_1 + (1-a)\hat{\theta}_2] \\ &= a^2\sigma_1 + (1-a)^2\sigma_2. \end{aligned}$$

Tomamos la derivada con respecto a a e igualamos a cero:

$$\begin{aligned} \frac{d}{da}(Var[\hat{\theta}_3]) &= 2a\sigma_1 - 2(1-a)\sigma_2 \\ &= 0 \\ a &= \frac{\sigma_2}{\sigma_1 + \sigma_2}. \end{aligned}$$

- (c) **¿Para qué valor de la constante a se minimiza la varianza de $\hat{\theta}_3$ si $\hat{\theta}_1$ y $\hat{\theta}_2$ no son independientes pero $Cov(\hat{\theta}_1, \hat{\theta}_2) = c \neq 0$?**

Ahora, la varianza de $\hat{\theta}_3$ sería:

$$Var[\hat{\theta}_3] = a^2\sigma_1 + (1-a)^2\sigma_2 + 2a(1-a)c.$$

Derivando con respecto a a y resolviendo para a :

$$\begin{aligned}\frac{d}{da}(Var[\hat{\theta}_3]) &= 2a\sigma_1 - 2(1-a)\sigma_2 + 2c - 4ac \\ &= 0 \\ a &= \frac{\sigma_2 - c}{\sigma_1 + \sigma_2 - 2c}.\end{aligned}$$

5. Sea x_1, \dots, x_n una secuencia de v.a.i.i con distribución $Binomial(m, p)$. Considere a $\hat{p} = \frac{x_i}{n}$ como un estimador del parámetro p .
- (a) ¿Es \hat{p} un estimador insesgado de p ?
 - (b) Encuentre la CICR para $V(\hat{p})$.
 - (c) ¿Es \hat{p} un estimador de varianza mínima?

Estimador \hat{p} para la Distribución Binomial

1. ¿Es \hat{p} un estimador insesgado de p ?

$$\begin{aligned}E[\hat{p}] &= E\left[\frac{x_i}{n}\right] \\ &= \frac{1}{n}E[x_i] \\ &= \frac{1}{n}(m \cdot p) \\ &= p.\end{aligned}$$

Dado que $E[\hat{p}] = p$, \hat{p} es un estimador insesgado para p .

2. Encuentre la CICR para $V(\hat{p})$.

$$\begin{aligned}V(\hat{p}) &= V\left(\frac{x_i}{n}\right) \\ &= \frac{1}{n^2}V(x_i) \\ &= \frac{1}{n^2}(m \cdot p \cdot (1-p)) \\ &= \frac{m \cdot p \cdot (1-p)}{n}.\end{aligned}$$

3. ¿Es \hat{p} un estimador de varianza mínima?

Verificación de la cota de Cramér-Rao para \hat{p}

Para verificar si \hat{p} cumple con la cota de Cramér-Rao, primero calculamos la información de Fisher. Dada una muestra de n observaciones x_1, x_2, \dots, x_n con distribución $Binomial(m, p)$, la función de masa de probabilidad (f.m.p.) para cada x_i es:

$$f(x_i; p) = \binom{m}{x_i} p^{x_i} (1-p)^{(m-x_i)}.$$

La log-verosimilitud l es:

$$\begin{aligned} l &= \log L \\ &= \sum_{i=1}^n \log f(x_i; p) \\ &= \sum_{i=1}^n \left(\log \binom{m}{x_i} + x_i \log p + (m - x_i) \log(1-p) \right). \end{aligned}$$

La primera derivada respecto de p es:

$$\frac{dl}{dp} = \sum_{i=1}^n \left(\frac{x_i}{p} - \frac{(m - x_i)}{(1-p)} \right).$$

La segunda derivada respecto de p es:

$$\frac{d^2 l}{dp^2} = - \sum_{i=1}^n \left(\frac{x_i}{p^2} + \frac{(m - x_i)}{(1-p)^2} \right).$$

La información de Fisher $I(p)$ se obtiene como:

$$\begin{aligned} I(p) &= -E \left[\frac{d^2 l}{dp^2} \right] \\ &= n \left(\frac{m}{p^2} + \frac{m}{(1-p)^2} \right) \\ &= \frac{m \cdot n}{p^2(1-p)^2}. \end{aligned}$$

La cota de Cramér-Rao (CRLB) es $1/I(p)$:

$$\text{CRLB} = \frac{p^2(1-p)^2}{m \cdot n}.$$

Ahora, la varianza de \hat{p} es $V(\hat{p}) = \frac{m \cdot p \cdot (1-p)}{n}$. Comparando $V(\hat{p})$ con CRLB, tenemos:

$$\begin{aligned} V(\hat{p}) &= \frac{m \cdot p \cdot (1-p)}{n}, \\ \text{CRLB} &= \frac{p^2(1-p)^2}{m \cdot n}. \end{aligned}$$

Si $V(\hat{p}) = \text{CRLB}$, entonces \hat{p} sería un estimador de varianza mínima. Sin embargo, al comparar las dos cantidades, tenemos que:

$$V(\hat{p}) \neq \text{CRLB}.$$

Por lo tanto, \hat{p} no es un estimador de varianza mínima de acuerdo con la cota de Cramér-Rao.